

Federated Learning을 이용한 서비스 우선순위 기반

최적의 AP 선택 기법*

이현규 조성아 정인홍 홍충선

경희대학교 컴퓨터공학과

sr9166@naver.com seongside@naver.com cxzgh135@naver.com cshong@khu.ac.kr

Service priority based AP Selection Technique by using Federated Learning

SeongAh Jo HyunGyu Lee InHong Jeong ChoogSeon Hong
Department of Computer Science and Engineering, Kyung Hee University

요 약

최근들어 다양한 스마트폰 어플리케이션이나 다양한 IoT 기기들이 등장하고 있다. 다양한 IoT 기기나 어플리케이션은 엄청난 양의 트래픽을 발생시킨다. 엄청난 양의 트래픽은 전송속도를 저하시킬 뿐만 아니라, 높은 Quality of Service(QoS)를 보장하기가 힘들다. 또한 이러한 문제점들을 보완하기 위해 다양한 트래픽 분산 기술이 빠른 속도로 발전하고 있으며, 본 논문에서는 다양한 서비스와 디바이스 및 유저에 따른 우선순위를 기반으로 트래픽을 분산 시키며, 기계학습 알고리즘으로 Long Short-Term Memory(LSTM)과 Federated Learning을 사용하여 트래픽을 예측한다. 이를 통해 최종적으로 각 모바일 단말기들은 최적의 AP를 선택하게 되어 QoS를 보장할 수 있게 되며, AP들의 부하를 분산시킴으로써 망의 효율성 또한 늘릴 수 있다.

1. 서 론

모바일 디바이스가 서비스를 제공하기 위해 AP(Access Point)와 Wi-Fi(Wireless Fidelity) 연결이 필요할 때, 먼저 주변 AP를 탐색하고 그들 중 하나를 선택하여 연결을 진행한다. 이 때, IEEE 802.11 표준에 의하면 수신 신호 강도(RSSI: Received Signal Strength Indication)가 가장 높은 AP를 선택한다. 그러나 RSSI 기반 선택 방식은 신호 세기만 고려하기 때문에, 해당 AP의 네트워크 상태를 고려하지 않아 서비스에 알맞은 네트워크 환경을 제공하기 어렵다. 따라서 이를 해결하기 위해 QoS를 고려한 AP Selection에 대한 많은 연구가 진행되어 왔다. 하지만 대부분의 연구는 단순히 네트워크에 관련된 변수들만 파라미터로 한정되어져 있다.[1]

본 논문에서는 네트워크의 상태변수 외에도 서비스, 모바일 단말기, 사용자에게 따른 우선순위를 기반으로 한 AP Selection 기법을 제안한다. 우선순위를 기반으로 한 AP Selection은 최종적으로 각 모바일 단말기들에게 최적의 AP를 선택하도록 하며 서비스별 QoS를 만족시키며, 슈퍼유저의 만족감을 극대화 시킨다.

이를 위해 기계학습 알고리즘으로 각 AP에서 LSTM을 사용하여 각각의 AP들의 트래픽을 예측하였으며, Federated Learning을 통하여 중앙 서버에서 모든 AP들의 파라미터를 한 번에 업데이트 하여 각 네트워크의 상황들을 모두 고려하였다.

2. 관련 연구

2.1 RNN with LSTM

순환 신경망(Recurrent Neural Networks; RNN)은 루프가 들어있고, 과거의 데이터가 미래에 영향을 줄 수 있는 구조를 가진 딥러닝 알고리즘의 하나이다. RNN은 특히 시계열(Time-Series)데이터를 분석하는 데 많이 쓰인다. 하지만 기존의 RNN은 gradient가 소실되거나(Vanishing) 발산하는(Exploding)하는 문제점이 있다.[2] 그리고 이 문제를 해결하기 위한 고안된 RNNs의 변형인 LSTM(Long Short-Term Memory)의 구조는 그림 1과 같다. LSTM에서 하나의 셀은 Cell State와 Input gate, Out gate, Forget gate 총 3가지의 게이트로 구




그림 1. LSTM의 구조

* "본 연구는 과학기술정보통신부 및 정보통신기획평가원의 SW중심대학 사업의 연구결과로 수행되었음"(2017-0-00093)

성되어 있다. 각각의 게이트는 가지고 있는 정보들 중에 무엇을 입력할 것인지, 출력할 건지, 잊을 건지를 정한다. 이를 통해 LSTM은 강제적으로 기울기 값을 유지하도록 하여 이러한 문제를 해결하고 오랜 시간의 연관성도 학습할 수 있는 장점이 있다.[3]

2.2 Federated Learning

통합 학습(Federated Learning; FL)은 흩어져 있는 데이터에 대한 신경 네트워크 학습을 가능하게 하는 분산 기계 학습 접근 방식이다. 중앙 집중식 학습 방식은 특히 휴대폰 사용자에게는 사생활 침해적이다. 휴대폰에 사용자의 개인정보에 민감한 데이터가 포함될 수 있기 때문이다. 중앙 집중식 학습 방식과 비교하여, 통합 학습은 각 사용자의 개인 정보를 포함하는 모든 데이터를 기기에 보관 하면서 기계 학습 모델을 공동으로 학습할 수 있도록 하는 분산 학습 접근 방식이다. 이러한 통합 학습 모델을 사용함으로써 앞으로의 기계 학습 모델은 서버의 컴퓨팅 리소스를 고려하지 않고 학습할 수 있으며, 사용자는 더 나은 서비스를 위해 개인 정보를 교환 할 필요가 없다.[4]

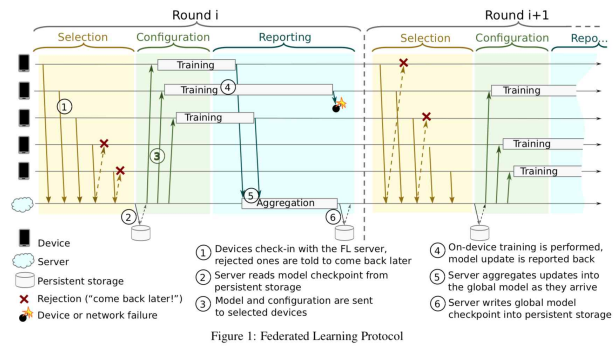


Figure 1: Federated Learning Protocol

그림 2. Federated Learning의 구조

3. 제안하는 알고리즘

3.1 기존 연구의 문제점 및 제안 사항

기존의 연구들은 RSSI값으로 AP Selection이 이루어졌을 때, 발생하는 문제를 해결하기 위해서 bit rate나 AP의 부하를 고려하여 QoS를 보장하는 알고리즘들을 제안했다.[5] 그러나 단순한 파라미터들만으로는 서비스, 디바이스, 유저 모두를 고려할 수 없으며, 현재 상황만을 고려하여 AP Selection을 결정했을 때, AP 연결 이후에 지속적인 QoS를 보장하기 힘들다는 문제점이 있다. 따라서 본 논문은 모바일 디바이스에서 서비스, 디바이스, 유저를 모두 고려한 우선순위를 선택하는 알고리즘을 제안하며, 디바이스에서 요구하는 트래픽과 주변 AP들의 네트워크 현재 상태와 기계 학습을 이용한 미래의 상태를 예측하여 가장 최적의 AP를 선택하는 알고리즘을 제안한다.

3.1 우선순위 결정 알고리즘

모바일 단말기 요청의 우선순위를 결정하기 위해 고려하는 요소는 실행중인 서비스의 요구 트래픽, 디바이스 레벨에 따른 우선순위, 유저 레벨에 따른 우선순위 총 3가지이다. 이 3가지 요소들을 모두 고려하여 AP 요청의 최종적인 우선순위를 결정하게 되며 이 우선순위를 통하여 AP Selection을 하게 된다.

P_{req} : (Priority of Request)
 T_{svc} : (Traffic of Service)
 P_{dev} : (Priority of Device)
 P_u : (Priority of User)

$$P_{req} = \alpha * T_{svc} + \beta * P_{dev} + \gamma * P_u$$

그림 3. Request의 우선순위 결정 알고리즘

3.2.2 AP Selection 알고리즘

Access Point Selection Algorithm

Input: P_{req} (Priority of Request), T_{cur} (Current Traffic)

Output: O_{ap} (Optimized AP)

1. T_{list} = Predicted future traffic list with LSTM
2. Sort T_{list}
3. $T_{lowest} = T_{list}[0]$
4. $O_{ap} = T_{lowest}.AP$
4. if $T_{lowest} > T_{max}$
5. P_{list} = Device Priorities in O_{ap}
6. Sort P_{list}
7. $P_{min} = P_{list}[0]$
8. if $P_{req} < P_{min}$
9. wait to lower traffic of AP
10. else
11. Disconnect Device which has P_{min}
12. return O_{ap}
13. else
14. return O_{ap}

그림 4 제안하는 알고리즘의 의사코드

그림 4는 Master AP에서 이루어지는 AP Selection 알고리즘을 의사코드로 나타낸 것이다. Master AP는 모바일 디바이스 요구사항 우선순위와 트래픽을 입력으로 받는다. 그리고 이를 통해 Master AP에 연결된 모든 AP에서 LSTM 모델을 이용하여 연결하였을 때의 트래픽을 수집한다. 수집된 트래픽중 가장 낮은 트래픽을 예측하는 AP를 최적의 AP라 가정하여 디바이스에게 그 AP의 정보를 알려준다. 정보를 받은 모바일 디바이스는 현재 AP의 연결을 끊은 후 최적의 AP로 연결을 한다. 만약 최적의 AP로 선정된 AP의 트래픽이 한계 트래픽 보다 높다면 우선순위를 기준으로 최하위의 디바이스를 강제로 AP에서 해제한다.

이러한 알고리즘을 적용하게 되면 결국 모든 모바일 단말기들은 최적의 AP를 가지게 되며 각각의 AP들은 네트워크 부하를 분산시킴으로써 망의 효율성을 증가시킬 수 있다.

3.2.3 Federated Learning

본 논문에서 사용하는 기계학습의 방식 중 한가지는 통합학습을 통하여 각 AP의 트래픽을 예측하는 LSTM 모델의 파라미터를 통합하여 업데이트 하는 방식이다. 각 AP들의 환경이 제각각 다르고 어떤 단말기가 어떤

트래픽을 요청하는지가 모두 다르기 때문에 각 기계학습 모델 별로 파라미터 값이 상이할 수 있게 된다. 이러한 문제점을 통합학습을 통하여 해결하였다. 통합학습의 여러 가지 파라미터 업데이트 방식 중 Federated SGD 방식[6]을 채택하였다. 그 결과 모든 LSTM의 파라미터가 동일하게 업데이트 되어 같은 입력 값이면 결과 값으로 동일한 예상 트래픽 값이 나왔다.

4. 성능 평가

4.1 시나리오

제안한 AP Selection 알고리즘을 평가하기 위해, 모바일 단말기에서 각각 유튜브, 게임, 인터넷등 여러 가지 서비스들을 실행시키면서 각 AP의 트래픽을 측정하였다. 기존의 AP Selection은 트래픽을 예상하지 않고 AP를 선택하기 때문에 한 AP에 상대적으로 많은 부하가 걸린다. 그러나 제안한 알고리즘은 트래픽을 예측하여 부하가 걸리면 우선순위에 따라 알맞은 AP를 결정하기 때문에 QoS를 지속적으로 보장할 수 있다. 또한 우선순위가 높은 단말기는 항상 원하는 AP에 연결되어 있고, 우선순위가 낮은 단말기는 LSTM이 예측한 트래픽의 결과가 한계 트래픽보다 높은 경우 다른 AP로 연결되는 것을 볼 수 있었다

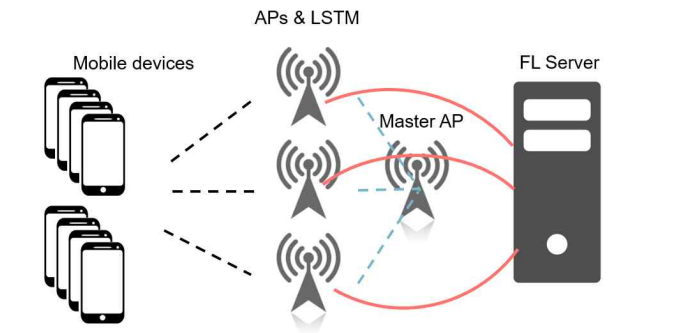


그림 5 시나리오 토폴로지

4.2 성능평가

제안되는 시나리오에서 모든 AP들의 트래픽이 한계치를 초과하지 않았으며, 신호세기가 강한 AP에만 연결이 집중되는 현상을 막고, AP들의 부하를 분산시켜 전체 네트워크 망의 효율성을 높였다. 표1과 그림 6을 보며 이를 위해 고안된 머신러닝 모듈인 LSTM의 정확도는 99%를 보였으며, 트래픽의 예측값 실 오차도 약 6.7 정도로 매우 정확성이 높음을 알 수 있다.

5. 결 론

본 논문은 다양한 모바일 서비스들의 QoS를 만족시키기 위해 각 단말기들의 AP 요청을 우선순위에 따라 최적의 AP Selection을 제안한다. 특히 딥 러닝 알고리즘인 LSTM과 FL을 활용한 트래픽의 예측 값을 사용하여 우선순위에 알맞은 최적의 AP를 결정한다. 그리고 시나리오 결과, 이를 통해 각 단말기들에 맞는 최적의 AP를 결정하기 때문에 지속적으로 QoS를 보장할 수 있고 AP들의 부하도 분산시킴으로써 망의 효율성도 높일

수 있었다. 향후에는 사용자 로그를 기반으로 서비스의 트래픽 또한 예측하여 모든 트래픽이 일정하지 않음을 고려하여, LSTM의 모델의 정확성을 더욱 높일 계획이다.




그림 6 LSTM의 트래픽 예측값

LSTM 트래픽 실 오차 평균값(byte)	6.75017095
LSTM 트래픽 예측 정확도	99.374051%

표 1 LSTM 성능 평가

참 고 문 헌

[1]이동규, 홍충선, "SDN 환경에서 머신러닝 기반 비디오 서비스를 위한 최적 AP 선택기법" 한국정보과학회 학술발표논문집, 2017.12, 1293-1295 (3pages).
[2]Tjeng Wawan Cenggoro, Ida Siahaan, "Dynamic Bandwidth Management Based on Traffic Prediction Using Deep Long Short Term Memory" International Conference on Science in Information Technology (ICSITech), pp.318-323, Oct 2016.
[3]S. Hochreiter and J. Schmidhuber, "Long short-term memory," Neural Computation, vol. 9, no. 8, pp. 1735-1780, Nov 1997.
[4]Keith Bonawitz, et al., "Towards Federated Learning at scale: system design" arXiv:1902.01046, Feb 2019.
[5]Keshav Sood, et al., "Dynamic Access Point Association Using Software Defined Networking" International Telecommunication Networks and Applications Conference (ITNAC) pp. 226-231, Nov 2015.
[6]H. Brendan McMahan Eider Moore Daniel Ramage Seth Hampson Blaise Aguera y Arcas, "Communication-Efficient Learning of Deep Networks from Decentralized Data" arXiv:1602.05629v3, Feb 2017.